Methodology, Ethics and Practice of Data Privacy

实验二

Lan Zhang
School of Computer Science and Technology
University of Science and Technology of China
Spring 2021

Part 1

横向联邦学习简要介绍

横向联邦学习的一种实现

- 对于每一个epoch

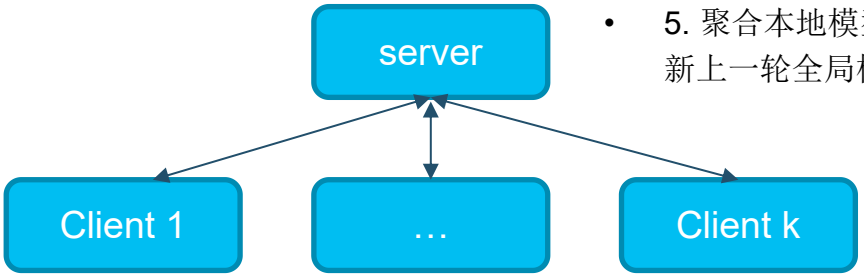

Server端

- 4. 收到来自client的梯度$[\Delta w_1, \Delta w_2, ..., \Delta w_k]$
- 5. 聚合本地模型更新$\Delta w_{avg} = \frac{\sum_{\{i=1\}}^{k} \Delta w_i}{k}$，更新上一轮全局模型，并发送给client

$$w_{t+1} = w_t + \frac{1}{k}\left(\sum_{i=0}^{k} \Delta w^i\right)$$

Client 端

- 1. 每个client 在自己的模型上训练local_epoch轮。
- 2. 求解local_epoch轮中参数的模型更新信息Δw
- 3. 将Δw上传到server端
- 6. 获取更新后的模型作为自己的模型。

横向联邦学习中的隐私问题

模型更新会泄露用户数据集信息

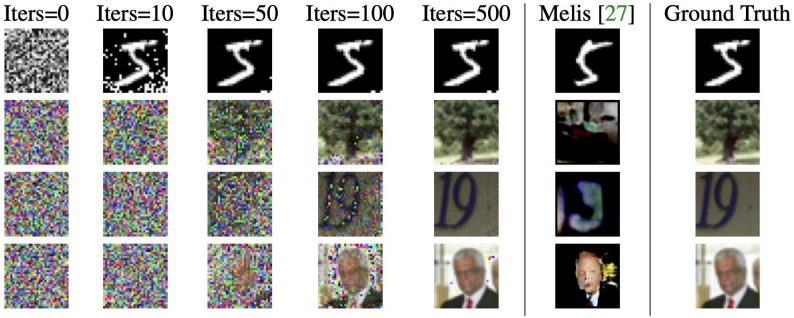

Figure 3: The visualization showing the deep leakage on images from MNIST [22], CIFAR-100 [21], SVHN [28] and LFW [14] respectively. Our algorithm fully recovers the four images while previous work only succeeds on simple images with clean backgrounds.

Zhu L, Han S. Deep leakage from gradients[M]//Federated Learning. Springer, Cham, 2020: 17-31.

Part 2

差分隐私机制在联邦学习中的应用

DP SGD in centralized model

- Stochastic gradient decent (SGD)

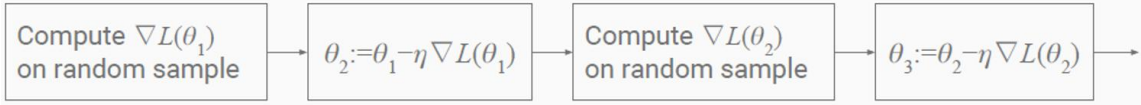

- Differentially Private SGD (DP SGD)

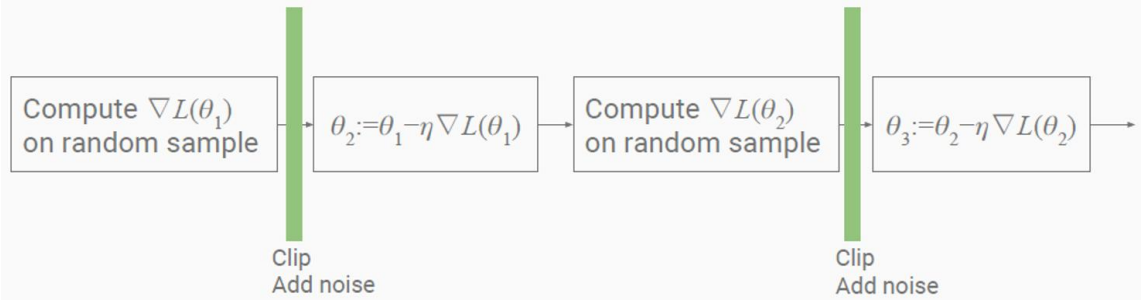

Martín Abadi, Andy Chu, Ian J. Goodfellow, H. Brendan McMahan, Ilya Mironov, Kunal Talwar, Li Zhang:
Deep Learning with Differential Privacy. ACM Conference on Computer and Communications Security 2016: 308-318

DP SGD in centralized model

» 算法描述

Algorithm 1 Differentially private SGD (Outline)

Input: Examples $\{x_1, \ldots, x_N\}$, loss function $\mathcal{L}(\theta) = \frac{1}{N}\sum_i \mathcal{L}(\theta, x_i)$. Parameters: learning rate η_t, noise scale σ, group size L, gradient norm bound C.

Initialize θ_0 randomly

for $t \in [T]$ **do**

Take a random sample L_t with sampling probability L/N

Compute gradient

For each $i \in L_t$, compute $\mathbf{g}_t(x_i) \leftarrow \nabla_\theta \mathcal{L}(\theta_t, x_i)$

Clip gradient

$\bar{\mathbf{g}}_t(x_i) \leftarrow \mathbf{g}_t(x_i) / \max\left(1, \frac{\|\mathbf{g}_t(x_i)\|_2}{C}\right)$

Add noise

$\tilde{\mathbf{g}}_t \leftarrow \frac{1}{L}\left(\sum_i \bar{\mathbf{g}}_t(x_i) + \mathcal{N}(0, \sigma^2 C^2 \mathbf{I})\right)$

Descent

$\theta_{t+1} \leftarrow \theta_t - \eta_t \tilde{\mathbf{g}}_t$

Output θ_T and compute the overall privacy cost (ε, δ) using a privacy accounting method.

Abadi, Martin, et al. "Deep learning with differential privacy."
Proceedings of the 2016 ACM SIGSAC conference on computer and communications security. 2016.

DP SGD in federated model

- 为了保护每个client的模型更新信息，对于每一个epoch

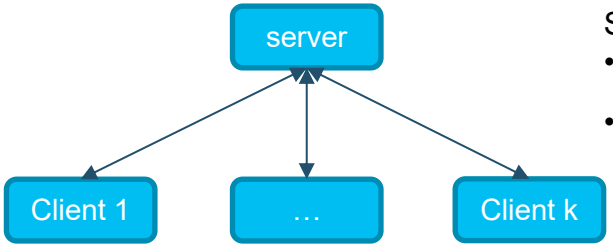

Server端

- 4. 收到来自client的梯度$[\Delta w_1, \Delta w_2, ..., \Delta w_k]$
- 5. 聚合本地模型更新$\Delta w_{avg} = \frac{\sum_{\{i=1\}}^{k} \Delta w_i}{k}$，更新上一轮全局模型，并发送给client

$$w_{t+1} = w_t + \frac{1}{k}\left(\sum_{i=0}^{k} \Delta w^i\right)$$

添加高斯机制

$$w_{t+1} = w_t + \frac{1}{k}\left(\sum_{i=0}^{k} \Delta w^i / \max\left(1, \frac{\left|\left|\Delta w^i\right|\right|_2}{C}\right) + N(0, \sigma^2 C^2 I)\right)$$

w_{t+1}指更新后的模型参数，w_t指原有的模型参数，k是指client数量， Δw^i是指用户i上传的模型更新，σ是高斯机制中的参数，C是模型更新的截断值，I是单位矩阵

高斯机制中的σ与$(\epsilon, \delta) - DP$的关系

$$w_{t+1} = w_t + \frac{1}{k}\left(\sum_{i=0}^{k} \Delta w^i\right)$$ 添加高斯机制 $$\Rightarrow \quad w_{t+1} = w_t + \frac{1}{k}\left(\sum_{i=0}^{k} \Delta w^i / \max\left(1, \frac{\left|\left|\Delta w^i\right|\right|_2}{C}\right) + N(0, \sigma^2 C^2 I)\right)$$

当σ满足以下定理时，添加高斯机制满足$(\boldsymbol{\epsilon}, \boldsymbol{\delta}) - DP$

Theorem 3.22. Let $\varepsilon \in (0, 1)$ be arbitrary. For $c^2 > 2\ln(1.25/\delta)$, the Gaussian Mechanism with parameter $\sigma \geq c\Delta_2(f)/\varepsilon$ is (ε, δ)-differentially private.

$$\sigma \geq \sqrt{2\ln\left(\frac{1.25}{\delta}\right)} * \frac{C}{\epsilon} \qquad (1)$$

TODO

- 基本内容
  - 在原有代码框架上添加上述DP机制
  - 代码正确，关键部分有注释
  - 实验说明参数 σ, C 对模型准确度的影响，并计算对应的ϵ值（$\delta = 10^{-3}$）
  - 实验报告（关键代码截图以及说明）
- 附加内容
  - 为了保证模型的可用性， σ取值较小，此时由公式(1)可能计算出$\epsilon \geq 1$， 不满足定理3.22的条件，因此无法由此定理证明满足DP。
  - 请调研当$\epsilon \geq 1$时，如何证明此机制满足DP；或调研是否存在其他机制可解决此问题。

Part 3

同态加密算法在联邦学习中的应用

Paillier 同态加密简介

- 加法同态加密
  - 加密情况下，仍然可以计算两个信息的和
  - given encryption of m_1 and m_2, one can compute the encryption of $m_1 + m_2$. $E(m_1) \oplus E(m_2) = E(m_1 + m_2)$

- Paillier: 一种基于公钥系统的加法同态和乘法半同台加密系统
  - 密钥生成
    随机并且独立选择两个***相同位数***大质数p, q.计算$n = pq$
    当$p \neq q$时，欧拉函数$\lambda = \phi(n) = (p-1)(q-1)$.
    当$p = q$时，欧拉函数$\lambda = \phi(n) = \mathrm{q}(q-1)$.
    选择一个整数$g = n + 1, \mu = \phi(n)^{-1} mod\ n$
    (μ有可能不存在，需要重新生成).
    公钥为(n, g),私钥为(λ, μ).
  - 加密
    消息$m(0 \leq m \leq n)$
    选择随机数r满足$0 < r < n$且$r \in \mathbb{Z}_n^*$(i.e.,保证$\gcd(r, n) = 1$)
    计算密文$c = g^m \cdot r^n mod\ n^2$

Paillier 同态加密简介

- Paillier: 一种基于公钥系统的加法同态加密系统
  - 解密

    密文$c \in \mathbb{Z}_{n^2}^*$

    明文$m = L\left(c^{\lambda} mod\ n^2\right) \cdot \mu\ mod\ n$, 其中$L(x) = \lfloor \frac{x-1}{n} \rfloor$, 表示$n$除$x-1$的商取下整
  - 密文加法

    $Dec(Enc(m_1, r_1) \cdot Enc(m_2, r_2) mod\ n^2) = m_1 + m_2 mod\ n$
  - 与明文常数加法

    $Dec(E(m_1, r_1) \cdot g^{m_2} mod\ n^2) = m_1 + m_2 mod\ n$
  - 与明文常数乘法

    $Dec(Enc(m_1, r_1)^k mod\ n^2) = k m_1 mod\ n$

Paillier 在横向联邦学习中的应用

- 为了保护client的模型更新信息，对于每一个epoch

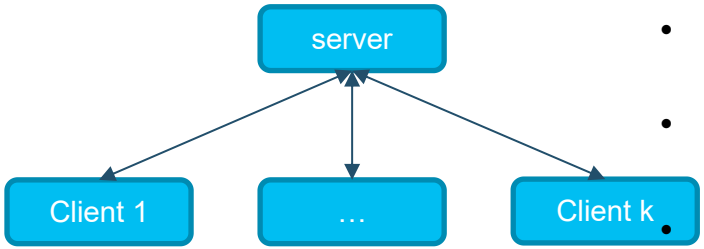

Server端

- 4. 收到来自client的加密模型更新信息 $[enc(\Delta w_i)]$
- 5. 利用同态加密，聚合各个梯度 $\Delta w_{avg} = \sum_{\{i=1\}}^{k} enc(\Delta w_i) \times \frac{1}{k}$
- 6. 将Δw_{avg}发送给各个client

Client 端

- 1. 每个client 在自己的模型上训练local_epoch轮。
- 2. 求解local_epoch轮中参数的更新Δw（默认client学习率公开且一致的情况下，可以用w_new-w_old代替)
- 3. 利用同态加密，将加密之后的$enc(\Delta w)$上传到server端
- 7. 利用收到的Δw_{avg}，更新自己的模型参数

Part2 实验内容

- 任务1：了解paillier原理
  - 使用gmpy2库填充paillier.py中enc, dec, enc_add enc_add_const和enc_mul_const函数，验证结果的正确性。
  - 测试密钥长度为1024位（二进制）时，长度10-1000bits整数加法，验证其结果是否正确，并合理测试运行时间。
- 任务2：paillier + federal learning
  - 为了防止server端获得client端的梯度和模型参数，使用paillier对于上传的模型更新进行加密和解密运算，并且实现在加密情况下的梯度聚合操作。
- 实验要求：
  - 任务1，实现结果正确，代码清晰
  - 任务2，实现结果正确，说明实现方法。对比模型在minst上的训练时间。

推荐实验工具

- Python 3.7及以上
- gmpy2库
  - https://www.lfd.uci.edu/~gohlke/pythonlibs/#gmpy提供了gmpy2-2.0.8-cp37-cp37m-win_amd64.whl以及支持其他python>3.4版本的的gmpy2库
  - 将whl文件下载到本地，并使用

Eg: (python -m) pip install gmpy2-2.0.8-cp37-cp37m-win_amd64.whl

进行安装

- https://gmpy2.readthedocs.io/en/latest/mpfr.html gmpy2的documentation
- 有可能会使用到的函数: mpz, powmod, invert, is_prime, random_state, mpz_urandomb, rint_round, log2, gcd

推荐实验工具

- python-paillier库
  - Python-paillier库的文档

  https://python-paillier.readthedocs.io/en/stable/index.html
  - pip install phe
- 说明：
  - 对于任务1，要求掌握paillier的原理，因此不能直接使用phe库进行加解密。
  - gmpy2库和phe库也不是必须的，同学们可以自行选择语言和实现方法。
  - Paillier如何应用在浮点数上，实验不要求掌握，可以直接使用现有的paillier的库进行实现

实验中用到的参数和数据

- 数据集 mnist, 使用torchvision.dataset 提供mnist数据集
- 每个client的网络结构

```
class CNNMnist(nn.Module):
    def __init__(self, args):
        super(CNNMnist, self).__init__()
        self.conv1 = nn.Conv2d(args.num_channels, 10, kernel_size=5)
        self.conv2 = nn.Conv2d(10, 20, kernel_size=5)
        self.conv2_drop = nn.Dropout2d()
        self.fc1 = nn.Linear(320, 50)
        self.fc2 = nn.Linear(50, args.num_classes)

    def forward(self, x):
        x = F.relu(F.max_pool2d(self.conv1(x), 2))
        x = F.relu(F.max_pool2d(self.conv2_drop(self.conv2(x)), 2))
        x = x.view(-1, x.shape[1]*x.shape[2]*x.shape[3])
        x = F.relu(self.fc1(x))
        x = F.dropout(x, training=self.training)
        x = self.fc2(x)
        return x
```

- Client数量，学习率等超参数：在options.py中定义

实验分数占比和截止日期

- Part 1
  - 基本内容　32’
  - 附加内容　8’
- Part 2
  - 任务1　30’
  - 任务2　30’
- 截止日期
  - 7.1号

THANKS!

Any questions?